

Projet LLM

Préparation :

Les premières étapes de ce projet ont été de récupérer le dossier contenant l'ensemble des informations sur celui-ci à l'aide d'un git clone, ainsi que de réaliser la création de notre base de données vectorielles en utilisant Upstash. De cette manière, j'ai pu configurer un index hybride fonctionnant par recherche de mots-clés (modèle BM25) et recherche sémantique dense (modèle BAAI/bge-m3 avec métrique COSINE) . Par la suite nous avons créé un environnement python afin de pouvoir utiliser la version 3.13 de python et aussi pouvoir réaliser les pip install qui seront nécessaires lors de la suite de notre projet. Enfin nous avons créé un fichier .env qui conserve les clé API OpenAI et Upstash, sans oublier de configurer .gitignore pour garantir que ces informations ne soient jamais publiées sur le dépôt public GitHub que l'on mettrait en place plus tard.

Mes données :

La mise en place de la base de données sur moi a commencé par la préparation de plusieurs fichiers Markdown (.md) au sein du répertoire data. Chaque répertoire était dédié à une facette de mon profil, comme par exemple : mes compétences (sur le plan humain et technique), ma formation, mes projets ou encore une brève présentation de qui je suis. J'ai dû porter une attention particulière à la structure de ces documents afin de pouvoir correctement organiser l'information, j'ai donc utilisé des titres hiérarchiques clairs à l'aide soit d'# (simple ou double en fonction du type d'infos). Tout ce travail préalable était indispensable pour l'étape suivante, en effet le découpage des documents (chunking), qui consiste à diviser les fichiers en segments cohérents afin de permettre à l'IA de retrouver l'information avec une plus grande précision lors du travail de requêtage que l'on effectuera par la suite. L'étape finale de la gestion de ces données a consisté en l'indexation dans Upstash, transformant mes fichiers Markdown en une base complète sur moi. À l'aide du SDK Python d'Upstash Vector, chaque chunk de texte a été converti en vecteurs numériques avant d'être par la suite injecté dans l'index. Ce processus permet de stocker non seulement le texte brut, mais aussi sa signification mathématique, facilitant ainsi la recherche par similarité cosinus. Grâce à ce travail, mon parcours est devenu intégralement consultable et exploitable par l'agent : lorsqu'un utilisateur pose une question, l'IA va comparer le vecteur de la requête avec ceux stockés dans Upstash pour extraire les informations les plus pertinentes de mon profil. Cette façon de procéder nous garantit que l'agent conversationnel ne va pas "deviner" des réponses, mais bien les puiser directement dans une source de données prévue pour me "représenter".

Agent IA :

Le cœur de ce projet repose sur la conception d'un agent intelligent. Contrairement à un modèle de langage statique, cet agent a été configuré pour fonctionner de manière à fonctionner en autonomie tout en étant capable de raisonner et d'agir selon des instructions précises en tant que mon assistant virtuel exclusif. Pour piloter cette intelligence, j'ai donc dû utiliser le modèle gpt-4.1-nano, un modèle performant, notamment pour les échanges.

La véritable valeur ajoutée de cet agent réside dans l'implémentation d'une architecture de type RAG, qui permet de pallier les limites de connaissances du modèle. Pour ce faire, j'ai développé un outil personnalisé, intégré directement à l'agent sous forme de fonction Python. Cet outil sert de passerelle entre l'IA et ma base de données vectorielle Upstash : à chaque sollicitation de l'utilisateur concernant mes compétences ou mes réalisations, l'agent déclenche automatiquement cet outil pour interroger mon index vectoriel. L'agent ne produit donc pas de réponses fondées sur des probabilités, mais génère des informations ancrées dans la réalité, en se servant de mon portfolio, en récupérant et en synthétisant les segments de documents les plus pertinents préalablement indexés. Cette approche garantit une précision accrue, élimine les erreurs courantes des LLM et permet la démonstration de ma capacité à connecter une IA à des sources de données à la fois dynamiques et structurées.

Interface Utilisateur et Déploiement Cloud

La concrétisation visuelle du projet a été réalisée via le Streamlit, permettant de transformer l'agent IA qui n'a pas vraiment d'interface en une application web interactive et accessible. L'interface a été réalisée relativement rapidement en utilisant GEMINI, sans s'être trop attardé sur l'esthétique de celle-ci. J'ai donc mis en place une boucle de rétroaction où les visiteurs peuvent interroger l'agent en temps réel, celui-ci affiche les réponses de manière dynamique après avoir consulté la base de connaissances.

Une fois l'application fonctionnelle en local, l'étape finale a consisté en son déploiement sur Streamlit Community Cloud. Durant le déploiement j'ai dû faire bien attention à la sécurité. Que le fichier .env étant exclu du dépôt GitHub par mesure de précaution, j'ai configuré les variables d'environnement critiques (clés API OpenAI et Upstash) directement via le gestionnaire de Secrets de la plateforme.

Lien de l'application : [Hugo Poisson - Assistant IA · Streamlit](#)

Lien GitHub : <https://github.com/hugopoisson312-pixel/portfolio-ia-hugo>